

Visão Computacional Aplicada ao Monitoramento de Chaves Seccionadoras de Subestações de Energia Elétrica^{*}

Tamires M. Rezende^{*} Bruno A. S. Oliveira^{*} Glaucio M. V. de Paula^{*}
Gustavo P. de Souza^{*} Daniel Calvo^{*} Eugênio L. Daher^{*}
Adriano O. da Silva^{**}

^{*} *Fundação de Inovações Tecnológicas (FITec), Av Cristóvão Colombo,
485, 8º Andar – Belo Horizonte, MG (e-mail:
{tamiresrezende,brunooliveira,glaucovianna,gpsouza,dcalvo,
edaher}@fitec.org.br).*

^{**} *Huawei do Brasil, R. Arquiteto Olavo Redig de Campos, 105 -
Chácara Santo Antônio (Zona Sul), São Paulo - SP, 04709-000
(e-mail: adriano.o.silva@huawei.com).*

Abstract: Over the years, electric power consumption has been increasing significantly, making it necessary to adopt measures to monitor the process up to the distribution, so that its supply is not interrupted. In that process, among the various devices that are part of the system, the proper monitoring of the operational state of the substation disconnect switches plays an important role. They are responsible for connecting the high voltage to the medium voltage, used to reconfigure the network and isolate the equipment for maintenance. In this scenario, this work developed a methodology for detecting 69kV disconnect switches and determining their operational state: opened or closed. The system applies computer vision techniques, aiming to generate a generalized model for real-time inference of the switches during the regular operation. The methodology incorporates image acquisition, data preparation, training with the tiny-YOLO algorithm, and testing of the model obtained. As a result, in face of the approached scenario, it was verified that the proposed solution can successfully detect correctly the state of the phases, achieving a mAP equals to 97.50%.

Resumo: Com o passar dos anos, o consumo de energia elétrica vem aumentando significativamente, tornando necessária a adoção de medidas de monitoramento do processo até a distribuição, para que o seu fornecimento não seja interrompido. Nesse processo, dentre os diversos dispositivos que fazem parte do sistema, é importante monitorar corretamente o estado operacional de chaves seccionadoras em subestações de energia. Elas são responsáveis por conectar a alta tensão com a média, utilizadas para reconfigurar a rede e isolar o equipamento para manutenção. Neste cenário, este trabalho desenvolveu uma metodologia para detecção das chaves seccionadoras de 69kV e posterior classificação do seu estado de operação: abertas ou fechadas. O sistema utiliza recursos de visão computacional, com o objetivo de gerar um modelo generalista para a inferência, em tempo real, das chaves em operação. A metodologia incorpora a aquisição de imagens, a preparação dos dados, treinamento com algoritmo tiny-YOLO e teste do modelo obtido. Como resultado, diante do cenário abordado, verificou-se que a solução proposta consegue com êxito detectar corretamente o estado das fases, tendo obtido um mAP de 97,50%.

Keywords: Computer Vision; Switches Disconnectors; Power Substation; YOLO algorithm; Monitoring; Object Detection.

Palavras-chaves: Visão Computacional; Chaves Seccionadoras; Subestação de Energia; algoritmo YOLO; Monitoramento; Detecção de Objetos.

1. INTRODUÇÃO

A Inteligência Artificial (IA) é uma área de pesquisa que possui ferramentas altamente utilizadas para resolver problemas no setor elétrico. As técnicas de IA atuam analisando dados, aprendendo com eles e tomando decisões de forma automática. A necessidade por inovações tecnológicas na área elétrica provem da busca por um melhor aproveitamento dos recursos ambientais, dado o crescente aumento no consumo de energia nos últimos anos (Oliveira et al., 2021b).

O processo para geração, transmissão e distribuição de energia elétrica necessita de um monitoramento criterioso de seus diversos dispositivos e componentes, devido a complexidade de fechamento do ciclo de produção. Perdas são naturais ao longo do processo, mas determinadas falhas precisam ser evitadas para que o produto final chegue na casa do consumidor ininterruptamente.

Subestações estão presentes na geração, transmissão e distribuição de energia e as chaves seccionadoras são responsáveis por reconfigurar a rede e isolar circuitos ou equipamentos para manutenção (Nassu et al., 2018). Elas podem ser operadas manualmente ou automaticamente e seu monitoramento se faz necessário para evitar acidentes, danificar equipamentos ou interrupções do serviço.

A realização de manobras nessas chaves, que são comandadas remotamente a partir de centros de operação das concessionárias de energia, é regida por normas e procedimentos que requerem a realização de inspeção visual para confirmar que as mesmas atuaram de forma correta. Em algumas empresas, essa inspeção é realizada in-loco por um técnico que, muitas vezes, precisa se deslocar fisicamente até a subestação. Com isso, pode acontecer dessa inspeção ser realizada em condições adversas de luminosidade e visibilidade, durante chuvas fortes ou durante a noite.

Diante deste cenário, este artigo propõe uma abordagem para identificar o estado das fases das chaves seccionadoras. A utilização de câmeras para visualização e inspeção remota dessas chaves reduziria e, eventualmente, poderia até mesmo eliminar a necessidade de deslocamento de um técnico, aumentando a disponibilidade do sistema e reduzindo custos.

Dessa forma, o objetivo deste trabalho foi proporcionar o desenvolvimento de um sistema de inspeção de chaves seccionadoras, em tempo real, incorporando técnicas de IA. O procedimento desenvolvido para detecção do estado de operação da chave consistiu na (i) aquisição de imagens que continham as chaves seccionadoras de 69kV (objeto do estudo), (ii) demarcação espacial dessas chaves nas imagens para que o modelo de IA aprenda o que é uma fase dessa chave e classifique o seu estado, (iii) treinamento desse modelo de aprendizado profundo utilizando o algoritmo Tiny-YOLO, (iv) análise e discussão dos resultados. Vale ressaltar que, por mais que esse artigo tenha o objetivo de detectar um objeto específico, a metodologia pode ser aplicada a outros cenários, detectar outros tipos de chaves, desde que o modelo seja treinado com dados que tenham imagens do objeto em questão.

* A pesquisa foi financiada pela Huawei do Brasil e desenvolvida na FITec Inovações Tecnológicas.

Este trabalho refere-se a um projeto prático e colaborativo, cujo principal desafio refere-se à disponibilidade de imagens para realizar o treinamento do modelo. Como em muitos outros trabalhos encontrados na literatura, trata-se de dados internos e, com isso, só podem ser acessados por colaboradores da empresa. Da parte da IA, várias são as técnicas encontradas na literatura para realizar a demarcação nas imagens e a detecção de objetos. As escolhas tomadas nessa pesquisa foram embasadas em trabalhos encontrados na literatura que realizaram esse tipo de tarefa e que obtiveram resultados promissores como, por exemplo, de Venâncio et al. (2021).

O restante do artigo está organizado da seguinte forma: a Seção 2 relata os trabalhos relacionados às soluções de Inteligência Artificial e Visão Computacional aplicadas a problemas em subestações de energia elétrica. Em seguida, a Seção 3 apresenta a base de dados, o algoritmo e o experimento realizado nesta pesquisa. Por fim, as Seções 4 e 5 descrevem os resultados e as conclusões desta pesquisa, respectivamente.

2. TRABALHOS RELACIONADOS

Alguns trabalhos na literatura fazem uso da inteligência artificial e visão computacional para a automatização de diferentes processos dentro de uma subestação de energia elétrica. Grande parte dos estudos identificados teve como foco a aplicação de métodos de IA para a detecção de falhas nos processos de geração e distribuição de energia em sistemas elétricos. Outros empregam recursos de visão computacional para classificar determinados objetos em subestações.

Em um sistema de geração de energia elétrica, avaliar periodicamente e corretamente o estado dos seus dispositivos é altamente recomendável. Uma das formas de se fazer essa avaliação é por meio de imagens em infravermelho. Por isso, Lin et al. (2016) propuseram um algoritmo baseado em Rede Neural Convolutiva (*Convolutional Neural Network* - CNN) para classificar o estado de alguns objetos que fazem parte do sistema elétrico. De acordo com os autores, os resultados alcançados superaram outros métodos comparados.

Fu et al. (2018) fizeram uso do método de detecção de objetos YOLO (*You Only Look Once*) para realizar o reconhecimento inteligente de quadros de distribuição de alta tensão em uma subestação de energia elétrica. Com uso da abordagem baseada em aprendizado profundo, o sistema proposto identificava e localizava uma chave, para que em seguida pudesse inferir seu estado atual. Já no estudo de Wang (2018), o autor empregou uma CNN para a avaliação do estado de quadros de distribuição. O treinamento do modelo considerou uma arquitetura de CNN pré-treinada no conjunto de imagens ILSVRC2012 (*ImageNet Large Scale Visual Recognition Challenge 2012*), sendo retreinado com o conjunto de dados personalizado e específico para o problema da pesquisa. Foi relatado que o método conseguiu atingir com eficiência o que lhe foi proposto, podendo ser aplicado em ambientes reais e possibilitando a redução do custo de operação na manutenção desses dispositivos.

Na pesquisa desenvolvida por Oliveira et al. (2020b) foi aplicada técnicas de visão computacional e aprendizado de máquina para classificação de componentes em alimentadores de subestações elétricas. Quatro arquiteturas de CNN foram comparadas: DenseNet, Inception, ResNet e SqueezeNet. Os autores coletaram 32 imagens em campo de diferentes alimentadores para que, posteriormente, pudessem aplicar técnicas de aumento de dados para melhorar a generalização dos modelos. Os resultados experimentais indicaram que ambas as arquiteturas tiveram o mesmo desempenho, não apresentando diferença significativa entre a precisão alcançada por elas para o problema proposto.

Outro parâmetro que pode ser monitorado é o aumento da temperatura interna em equipamentos elétricos de forma a evitar danos aos instrumentos. Ullah et al. (2020) apresenta uma abordagem com análise de imagens para o reconhecimento de equipamentos que necessitam de manutenção. Foi utilizada uma arquitetura de CNN, AlexNet, retreinando o modelo com imagens dos equipamentos personalizados para o problema, com base no aprendizado por transferência. Com os recursos extraídos pela rede, o *Random Forest* e o *Support Vector Machine* (SVM) foram usados para classificar se o equipamento estava com defeito ou não.

A evolução das tecnologias que envolvem a indústria 4.0 também se faz presente neste contexto com o foco de tornar as subestações inteligentes e autônomas. Uma das principais aplicações está no uso de robôs de inspeção para a leitura automática de medidores. Dado a dificuldade para obtenção de imagens com qualidade, a ideia da pesquisa de Liu et al. (2020) foi aplicar o método de detecção de objetos *Faster R-CNN* para possibilitar ao sistema que primeiro seja encontrada a posição exata do medidor e, em seguida, a câmera do robô pudesse ajustar o melhor ângulo do medidor na imagem, de modo que o objeto ficasse nítido e com qualidade. Por fim, obtida a imagem do medidor, foi possível fazer o reconhecimento dele. Segundo os autores, o sistema demonstrou estabilidade e funcionou bem em diferentes condições.

Ainda com o objetivo de realizar o monitoramento automático de subestações de energia elétrica por meio de visão computacional, Oliveira et al. (2020a) propuseram uma prova de conceito empregando o método de detecção de objetos YOLO em um conjunto de dados coletados na internet, que correspondem a dispositivos que fazem parte de uma subestação de energia. De acordo com os resultados obtidos, pôde-se concluir que é possível contribuir no monitoramento para gestão de obras com pesquisas deste ramo.

Como já colocado, nos últimos anos inúmeras soluções para o monitoramento de subestações foram propostas, sendo que grande parte delas foi utilizando recursos de visão computacional e processamento digital de imagens. Na pesquisa de Jadia e Chawla (2020) foi proposta a classificação de isoladores de cerâmica e vidro, empregando a técnica *Speeded Up Robust Features* (SURF), que consegue extrair os principais recursos de uma imagem, recursos esses que podem ser de cor, textura, forma etc. Após a obtenção das características mais relevantes, a técnica *k-Nearest Neighbors* (KNN) foi utilizada para classificação.

Os autores destacaram que a solução proposta obteve um bom desempenho, podendo ser estendida a sistemas de segurança, vigilância e inspeção.

Por último, Oliveira et al. (2021a) apresentou uma evolução dos trabalhos de Oliveira et al. (2020b,a) descrevendo uma plataforma completa para o gerenciamento da construção de alimentadores em subestações de energia elétrica. Os autores experimentaram diferentes arquiteturas de CNN e incorporaram técnicas de processamento digital de imagens para auxiliar a tomada de decisão e monitorar a evolução das construções. Para o treinamento dos modelos foram obtidas milhares de imagens reais coletadas de dentro de subestações que continham obras sendo realizadas, fazendo com o que o conjunto de dados real implicasse diretamente na qualidade da solução para monitoramentos futuros. Os resultados obtidos mostram que o sistema foi capaz de cumprir com o objetivo proposto, até mesmo ao ser instalado em subestações diferentes que não fizeram parte do conjunto de treinamento.

Assim como apresentado, diversos trabalhos podem ser encontrados na literatura que fazem uso de técnicas de visão computacional e inteligência artificial no contexto de sistemas elétricos. De todos os estudos abordados, não foi encontrado nenhum que fosse desenvolvido sob medida para a classificação do estado de chaves de 69kV, justificando o desenvolvimento da atual pesquisa. Além disso, como contribuição do estudo, tem-se a possibilidade de alavancar ainda mais desenvolvimentos de trabalhos usando inteligência artificial no contexto de sistemas elétricos, bem como apresentar as vantagens da aplicação desses recursos para o setor.

3. MATERIAL E MÉTODOS

O objetivo deste estudo foi desenvolver uma metodologia para o aprendizado do estado das chaves seccionadores, seguindo as etapas básicas de sistemas de aprendizado de máquina, como ilustra a Figura 1. Com o treinamento realizado, almeja-se que o modelo possa ser utilizado para a inspeção, em tempo real, das chaves em subestação de energia.

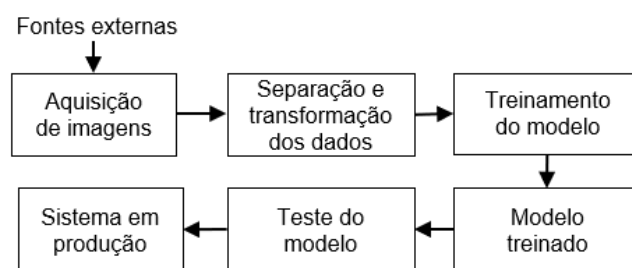


Figura 1. Pipeline de desenvolvimento do estudo.

Os estágios apresentados na Figura 1 representam a geração do modelo treinado para a inferência. Na *Aquisição de imagens* os elementos que serão processados pelo sistema são capturados. A consolidação desse estágio resulta no que se chama de Base de Dados (*dataset*), isto é, um conjunto de imagens. Os dados precisam representar de forma proporcional todos os estados e condições aos quais o objeto que será detectado/classificado está exposto. Já

na *Separação e transformação dos dados* as imagens serão preparadas com técnicas de variação e aumento dos dados, por exemplo, para serem utilizadas no treinamento do modelo. O *Treinamento do modelo* se refere ao algoritmo que realizará o aprendizado de um determinado padrão. A saída dessa etapa é o *Modelo treinado*, que representa o resultado do aprendizado. Vale ressaltar que uma parte dos dados é utilizada para o processo de aprendizado (treinamento), enquanto que, dados não vistos pelo modelo anteriormente (dados de teste) são utilizados para autenticação do conhecimento adquirido. Por fim, o modelo treinado e testado é colocado em produção.

3.1 Base de Dados

Para que a máquina aprenda a detectar, reconhecer e classificar objetos é necessário que ela receba dados que representem suas características. No caso desta pesquisa, o algoritmo implementado recebe imagens da chave seccionadora nas suas variações de operação (aberta e fechada) e condições ambientais e, de acordo com a forma física que ela assume em cada um dos estados, uma metodologia foi estruturada para que o processo de aprendizado ocorra.

O conjunto de dados desta pesquisa é formado por imagens de chaves seccionadoras de 69kV capturadas em subestação de distribuição de energia (*site survey*¹) e de dois vídeos disponíveis na internet, conforme apresentado na Tabela 1. Nas 91 imagens existentes, há a representação de 200 fases em estado aberto e 43 fases com contato fechado, como ilustra a Figura 2. O funcionamento ideal de uma chave é quando todas as três fases (sistema trifásico) se encontram no mesmo estado de operação. Entretanto, para este estudo, será realizado a análise das fases isoladamente.

Com a apresentação da Tabela 1, a base de dados construída possui poucas amostras e classes altamente desbalanceadas. As amostras da classe “fechada” foram obtidas por meio dos vídeos do *YouTube*. Por se tratar de um estudo de caso prático, um dos desafios é (também) lidar com poucos dados e gerar valor para o negócio. Este cenário caracteriza uma situação real do mercado de trabalho, com foco em um objeto específico de estudo: chaves seccionadoras de 69kV.

3.2 Algoritmo

A literatura disponibiliza diversos métodos e metodologias que permitem realizar o reconhecimento automático de objetos por meio de imagens. Essa é uma área em considerável crescimento desde os anos 90 devido ao surgimento de ferramentas de Visão Computacional, que permitem a extração e interpretação das imagens, propiciando o desenvolvimento da capacidade de percepção da máquina.

Diante de uma vasta lista de opções, nesta pesquisa optou-se por utilizar o YOLO. Ele é estado da arte na tarefa de detecção de objetos de único estágio atualmente disponível (de Venâncio et al., 2021) e de reconhecimento de objetos em tempo real. Foi originalmente proposto por Redmon et al. (2016) e, atualmente, está na sua sétima

¹ Como este é um projeto colaborativo, as imagens capturadas durante essa visita técnica podem ser acessadas apenas pelos colaboradores da empresa/projeto.




Figura 2. Chaves seccionadoras de 69kV (sistema trifásico). Exemplos retirados do conjunto de dados obtido no (a) *Site Survey* e dos vídeos do (b/c) *YouTube*.

versão. Como sugerido pelo seu nome, o YOLO é capaz de identificar, numa única execução, se existem objetos de interesse na cena e onde eles estão localizados.

O algoritmo funciona da seguinte forma: ele redimensiona a imagem de entrada para $n \times n$ pixels e depois a divide em uma grade de células $s \times s$ não sobrepostas. Cada uma das células está associada a probabilidades de classe C e caixas delimitadoras, com uma pontuação de confiança atribuída a cada caixa delimitadora. Como neste problema tem $C = 2$, cada célula i é representada por:

$$\mathcal{C}_i = [c_{i1}, c_{i2}, p_{i1}, x_{i1}, y_{i1}, h_{i1}, w_{i1}, \dots, p_{i2}, x_{i2}, y_{i2}, h_{i2}, w_{i2}] \quad (1)$$

onde p é a probabilidade (pontuação de confiança) de que a caixa delimitadora contenha um objeto de uma determinada classe, x e y são as coordenadas do centro da caixa delimitadora, h e w são a altura e largura da caixa delimitadora, respectivamente, e c_{i1} e c_{i2} são as probabilidades que o objeto detectado na célula i pertencer à classe 1 e 2, respectivamente.

Um objeto é considerado de uma determinada classe se sua pontuação de confiança estiver acima de um determinado limite t_{conf} . Cada caixa delimitadora será atribuída à classe com a maior pontuação. Como esse processo demanda um alto custo computacional que geralmente requer o uso de unidades de processamento de gráficos (GPUs) para treinamento e detecção, os autores YOLOv4 propuseram uma versão simplificada em termos de camadas e, portanto, mais rápida do YOLO: Tiny-YOLOv4 (Bochkovskiy et al., 2020).

Tabela 1. Base de Dados.

| Fonte | Número de Imagens | Fases Abertas | Fases Fechadas | Descrição |
|----------------------|-------------------|---------------|----------------|--|
| <i>Site Survey</i> * | 53 | 129 | 0 | Imagens de diversos ângulos e mostrando uma ou mais fases chave |
| <i>YouTube 1</i> ** | 25 | 45 | 30 | Imagens extraídas de um vídeo do <i>youtube</i> . Elas configuram a operação de três fases de uma chave seccionadora de 69kV |
| <i>YouTube 2</i> *** | 13 | 26 | 13 | Vídeo de uma manutenção em chaves seccionadoras de 69kV. Em todas as imagens há uma das fases fechada e as outras duas abertas |

*Figura 2(a)

**Figura 2(b). Fonte: <https://www.youtube.com/watch?v=8mwsFi-6-Cs>

***Figura 2(c). Fonte: <https://www.youtube.com/watch?v=Jf20BvabNw0>

Em suma, o YOLO é uma rede neural profunda que divide a imagem em pequenas regiões e prevê: (i) caixas delimitadoras e a (ii) probabilidade para cada região. Isso significa que o algoritmo recebe a imagem e apresenta como saída a classe do objeto contido na cena, seu *bounding box* e sua probabilidade.

3.3 Experimento

Demarcação das chaves seccionadoras: Para que o modelo de IA realize a inspeção da chave seccionadora, primeiramente ele precisa “entender” o que é uma chave e, posteriormente, aprender a classificar o seu estado. O primeiro processo realizado para preparar os dados foi a marcação das chaves seccionadoras nas imagens do *dataset*. A ferramenta BBox-Label (Qiu, 2017), desenvolvida em python, foi utilizada para realizar essa tarefa, definindo, inicialmente, dois estados para as fases das chaves: *Open* e *Close*. Esse é um trabalho manual e que demanda tempo, pois tem que ser feito com atenção e por imagem. Como mostra a Figura 3, de acordo com a classe escolhida (lado direito superior na figura), a caixa é desenhada demarcando a chave.



Figura 3. Demarcação das chaves seccionadoras.

Na literatura, há abordagens que demarcam apenas a parte vertical a chave (isoladores), entretanto nesse caso isso não é aconselhável pois o cenário da subestação possui muitas estruturas com a forma física similares, podendo gerar confusão por parte do algoritmo. Dessa forma, a demarcação foi realizada contornando toda a chave.

Ao final desse processo, cada imagem possui um arquivo com as anotações de cada imagem: as coordenadas dos *bounding boxes* indicando as posições das chaves e as classes associadas (*OPEN* ou *CLOSE*).

Transformação: O algoritmo YOLO redimensiona todas as imagens e para que ele consiga interpretar os valores das coordenadas dos *bounding boxes*, fez-se necessário transformar as anotações obtidas na etapa anterior. Com isso, as dimensões foram normalizadas de [0,1] e, agora, o algoritmo receberá arquivo que contém o ID da classe (0-*OPEN* e 1-*CLOSE*), a coordenada do centro da caixa delimitadora, a largura e a altura da mesma:

$\langle \text{classeID} \rangle \langle x \rangle \langle y \rangle \langle \text{largura} \rangle \langle \text{altura} \rangle$

Separação dos dados: De posse das imagens rotuladas pelo estado de operação das chaves (Classes: *Open*, *Close* e *OpenClose*²), aleatoriamente, 80% dos dados foram separados para treinamento e 20% para teste, sendo que essa divisão foi realizada pelo *label* que cada imagem recebeu. Isso significa que 72 imagens foram utilizadas para que o algoritmo aprenda a detectar e classificar o estado das chaves, e com as 19 imagens restantes é possível analisar se ele realmente compreendeu o padrão desejado. As imagens utilizadas no teste não foram “vistas” pelo algoritmo de treinamento.

Ambiente de treinamento: Para realizar o aprendizado foi utilizada a rede Tiny-YOLOv4 pré-treinada no *dataset* MS COCO, disponibilizada no site do *framework* darknet³, e as configurações presentes no arquivo “yolov4-tiny.cfg”⁴. Essa tática de utilizar pesos pré definidos aumenta a velocidade da rede, pois ela parte de um conhecimento prévio. O treinamento desse modelo utilizou como entrada as 72 imagens (= 80% dos dados). O ambiente utilizado foi o *Huawei Cloud*⁵, mais precisamente o *ModelArts*⁶ que é uma plataforma de desenvolvimento de IA que permite a construção, o treinamento, a implementação e a implantação de modelo, desde a nuvem até a borda. Dentre as variadas opções para desenvolvimento que a plataforma disponibiliza, neste artigo foi utilizado o modo *Notebook Instances*. Os dados foram armazenado no *Object Storage Service*⁷ que fornece armazenamento em nuvem estável, seguro, eficiente e fácil de usar.

² *OpenClose* foi a denominação dada as imagens que continham fases abertas e fechada em uma mesma cena.

³ Framework Darknet: <https://github.com/AlexeyAB/darknet>.

⁴ <https://gitlab.com/tamiresrezende/tiny-yolov4.git>

⁵ Huawei Cloud: <https://www.huaweicloud.com/intl/pt-br/?ned>.

⁶ ModelArts: <https://www.huaweicloud.com/intl/pt-br/product/modelarts.html>.

⁷ Object Storage Service: <https://www.huaweicloud.com/intl/en-us/product/obs.html>.

4. RESULTADOS E DISCUSSÃO

O treinamento do modelo é a etapa que realiza o aprendizado de um determinado padrão. No caso deste trabalho, esta etapa é responsável por aprender a definir o estado de operação de uma ou mais fases da uma chave seccionadora. Para isso, o modelo precisa detectá-las em uma cena e classificar os seus estados como aberta ou fechada. Para avaliar este aprendizado, algumas métricas de desempenho foram analisadas:

- Precisão: é a razão entre o número de amostras positivas corretamente classificadas e o número total de exemplos identificados como positivos pelo classificador, isto é, a porcentagem correta das previsões.
- Revocação: é a razão entre o número de amostras positivas corretamente classificadas e o número total de exemplos positivos originais, isto é, a capacidade de um modelo para encontrar todos os casos relevantes dentro de um conjunto de dados.
- F1-score: é uma média harmônica entre a precisão e a revocação.
- IoU: mede a sobreposição entre duas áreas.
- mAP: precisão média (AP) é uma métrica popular na medição da precisão dos detectores de objetos. A mAP é dependente das métricas anteriormente citadas, sendo considerada a principal forma de medir a qualidade de modelos de detecção de objetos.

Essas métricas avaliam, basicamente, as taxas de acerto para cada classe. A precisão pode ser usada em uma situação em que os falsos positivos (FP) são considerados mais prejudiciais que os falsos negativos (FN) e a revocação pode ser usada em uma situação em que os FN's são considerados mais prejudiciais que os FP's. Neste trabalho, ambas as situações são importantes e não é interessante que a porcentagem de valores falsos seja elevada.

Com o modelo treinado, os resultados obtidos no conjunto de teste estão sumarizados na Tabela 2. A análise foi realizada em termos de acurácia, FP, FN, TP⁸, precisão e revocação. A acurácia do modelo apresentou valores acima de 95% para ambas as classes e, para um IoU de 50%, a taxa de acerto média do modelo foi de 97,50% (mAP@0,5). Os resultados alcançados se mostraram promissores diante do conjunto limitado de dados que se possui.

Tabela 2. Resultados.

| Classe | ID | Acurácia | FP | FN | TP | Precisão | Revocação |
|--------|----|----------|----|----|----|----------|-----------|
| OPEN | 0 | 95,21% | 3 | 4 | 31 | 91% | 88% |
| CLOSE | 1 | 100% | 0 | 0 | 8 | 100% | 100% |

A Figura 4 apresenta dois exemplos de detecções e classificações corretas realizadas pelo modelo. Em ambos os casos, o algoritmo retornou uma taxa acima de 99% de probabilidade do *bounding box* ser da classe à qual ele inferiu. Já na Figura 5 houve acertos, mas verifica-se caixas delimitadoras que detectaram elementos da subestação que não são componentes da chave seccionadora (Figura 4(a)), além de deixarem de realizar a inferência em uma delas (Figura 4(b)).

⁸ Os termos FP, FN e TP se referem, respectivamente, a) falsos positivos: são classificados como da classe, mas de fato não são; b) falsos negativos: não são classificados como da classe, mas são; e c) verdadeiros positivos: classificações corretas da classe.

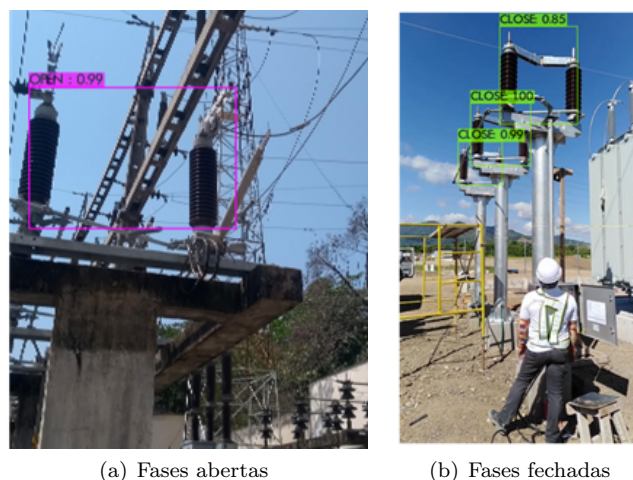


Figura 4. Teste do modelo: classificações corretas.

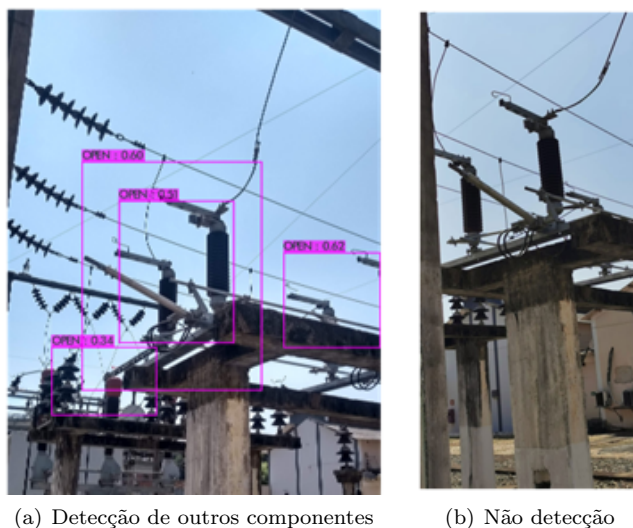


Figura 5. Teste do modelo: classificações incorretas ou faltantes.

Dessa forma, pôde-se verificar quantitativamente e qualitativamente a eficiência do método de detecção de objetos Tiny-YOLOv4 em identificar corretamente o estado das fases da chave seccionadora em subestações de energia elétrica, considerando as imagens coletadas e o cenário proposto. Por se tratar de uma primeira abordagem aplicada ao problema prático, algumas melhorias podem ser efetuadas para minimizar os FP's e os FN's: realizar o ajuste fino dos parâmetros, testar outras versões do YOLO, outros algoritmos de detecção e uma análise criteriosa das amostras que o algoritmo classificou erroneamente.

Além disso, a qualidade do conjunto de dados é outro assunto de destaque neste e em outros estudos da literatura. Neste trabalho, em específico, o número de amostras e a proporção de cada classe são pontos críticos e que afetam diretamente os resultados. O resultado das métricas é dependente da qualidade dos dados.

5. CONSIDERAÇÕES FINAIS

Este trabalho apresentou uma abordagem baseada em imagens para detecção e classificação de fases de chaves

seccionadoras de 69kV em subestações de distribuição de energia. O procedimento adotado nessa abordagem foi (i) aquisição das imagens, (ii) demarcação manual das fases e a rotulação do estado de operação delas em cada cena, (iii) implementação do algoritmo Tiny-YOLOv4 e (iv) análise dos resultados. Com essa metodologia, alcançou-se uma precisão e revocação de 91% e 88%, respectivamente, para a classe 0 (fase aberta) e uma precisão e revocação de 100% para a classe 1 (fase fechada).

Os resultados mostraram que o aprendizado foi realizado de forma satisfatória, uma vez que o algoritmo detectou e classificou bem as fases das chaves seccionadoras. Entretanto, há a necessidade de refinamentos no modelo para que os falsos valores (FP e FN) sejam minimizados.

Em trabalhos futuros, melhorias podem ser realizadas, na construção de uma base de dados robusta e consistente, incluindo mais imagens ao *dataset*, além de realizar testes com outras redes de aprendizado profundo e desenvolver uma metodologia que permita um resultado mais generalista. Isso é possível aplicando técnicas de aumento de dados, validação cruzada e análise de outras métricas de desempenho. O objetivo principal é que o modelo tenha a capacidade de classificar o estado de diversos modelos de chaves tipicamente utilizadas em subestações de energia.

AGRADECIMENTOS

Os autores agradecem o financiamento da pesquisa proporcionada pela Huawei⁹ e a oportunidade do desenvolvimento do trabalho nas dependências da FITec - Inovações Tecnológicas¹⁰.

REFERÊNCIAS

- Bochkovskiy, A., Wang, C.Y., e Liao, H.Y.M. (2020). YOLOv4: Optimal Speed and Accuracy of Object Detection. *arXiv preprint arXiv:2004.10934*.
- de Venâncio, P.V.A., Rezende, T.M., Lisboa, A.C., e Barbosa, A.V. (2021). Fire detection based on a two-dimensional convolutional neural network and temporal analysis. *7th IEEE LA-CCI (Latin American Conference on Computational Intelligence)*.
- Fu, C.Z., Si, W.R., Huang, H., Chen, L., Gao, Q.J., Shi, C.B., e Wang, C. (2018). Research on a detection and recognition algorithm for high-voltage switch cabinet based on deep learning with an improved yolo2 network. In *2018 11th International Conference on Intelligent Computation Technology and Automation (ICICTA)*, 346–350. IEEE.
- Jadia, A. e Chawla, M. (2020). Image classification and detection of insulators using bag of visual words and speeded up robust features. *International Journal of Innovative Science and Modern Engineering (IJISME)*, 6, 7–13.
- Lin, Y., Sun, J., Li, C., Ma, Y., Geng, Y., e Chen, Y. (2016). Deep learning for intelligent substation device infrared fault image analysis. In *MATEC Web of Conferences*, volume 55, 03007. EDP Sciences.
- Liu, Y., Liu, J., e Ke, Y. (2020). A detection and recognition system of pointer meters in substations based on computer vision. *Measurement*, 152, 107333.
- Nassu, B.T., Lippmann, L., Marchesi, B., Canestraro, A., Wagner, R., e Zarnicinski, V. (2018). Image-based state recognition for disconnect switches in electric power distribution substations. In *2018 31st SIBGRAPI Conference on Graphics, Patterns and Images (SIBGRAPI)*, 432–439. IEEE.
- Oliveira, B.A.S., de Faria Neto, A.P., Fernandino, R.M.A., Carvalho, R.F., de Proença Costa, D., e Guimarães, F.G. (2020a). Deep learning para detecção de componentes em alimentadores de subestações. In *Simpósio Brasileiro de Telecomunicações e Processamento de Sinais-SBrT*, volume 1.
- Oliveira, B.A.S., de Faria Neto, A.P., Fernandino, R.M.A., Carvalho, R.F., de Proença Costa, D., e Guimarães, F.G. (2020b). Visão computacional e aprendizado de máquina para classificação de componentes em alimentadores de subestações elétricas. In *Congresso Brasileiro de Automática-CBA*, volume 2. doi:10.48011/asba.v2i1.1599.
- Oliveira, B.A.S., De Faria Neto, A.P., Fernandino, R.M.A., Carvalho, R.F., Fernandes, A.L., e Guimarães, F.G. (2021a). Automated monitoring of construction sites of electric power substations using deep learning. *IEEE Access*, 9, 19195–19207. doi:10.1109/ACCESS.2021.3054468.
- Oliveira, B.A.S., Neto, A.P.D.F., Fernandino, R.M.A., Carvalho, R.F., Fernandes, A.L., e Guimaraes, F.G. (2021b). Automated monitoring of construction sites of electric power substations using deep learning. *IEEE Access*, 9, 19195–19207.
- Qiu, S. (2017). Bbox-label-tool. URL <https://github.com/puzzledqs/BBox-Label-Tool>.
- Redmon, J., Divvala, S., Girshick, R., e Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, 779–788.
- Ullah, I., Khan, R.U., Yang, F., e Wuttisittikulkij, L. (2020). Deep learning image-based defect detection in high voltage electrical equipment. *Energies*, 13(2), 392.
- Wang, J. (2018). Deep learning based state recognition of substation switches. *AIP Conference Proceedings*, 1971(1), 040041.

⁹ Huawei do Brasil: <https://www.huawei.com/br/>.

¹⁰ FITec - Inovações Tecnológicas: <https://www.fitec.org.br/>.